

Autoría: Marck Murillo

INFORME DE PROYECTO

Clasificador de vibraciones


Fecha: Julio 2025

ÍNDICE

- 01. Enfoques anteriores
- 02. Enfoques nuevos
- 03. Conjuntos de datos
- 04. Modelos más populares

ENFOQUES ANTERIORES

- Filtros con transformadas como Fourier o wavelet



ENFOQUES ANTERIORES

Mejoras

- Para wavelet búsqueda de la escala, periodo con entropía de shanon y decomposición de valores singulares
- Transformada Wavelet No-Diezmada (UWT) para mantener la invariancia a la traslación.
- Filtrado por Deconvolución de Entropía Mínima (MED) para resaltar impulsos.

MODELOS DE ML

- Redes neuronales profundas (DNN)
- Redes neuronales Convolucionales (CNN),
- Auto-codificadores profundos (DAE)
- Redes de creencia profunda (DBN)
- La memoria a largo y corto plazo (LSTM)
- Aprendizaje por transferencia (TL).
- DL como autoencoders (AE),
- Redes generativas adversarias (GAN),
- Redes neuronales recurrentes (RNN),

CONJUNTOS DE DATOS

A. CONJUNTO DE DATOS CWRU

El conjunto de datos de la Universidad Case Western Reserve (CWRU) es uno de los más populares, de código abierto y fácilmente accesible.

proporciona acceso a datos de rodamientos normales y defectuosos, se recopilaron datos para rodamientos normales, con defectos puntuales en el extremo del eje (Drive-End, DE) y en el extremo del ventilador




FIGURE 1. (a) An Experimental platform of the CWRU bearing test rig for ball bearing system [3], [4], the components of REB, and (b) its cross-sectional view.

CONJUNTOS DE DATOS

B. CONJUNTO DE DATOS DE LA UNIVERSIDAD DE PADERBORN

Los componentes principales del banco de pruebas incluyen un motor de accionamiento, un eje de medición de torque, un módulo de prueba y un motor de carga.

El conjunto de datos de Paderborn consiste en datos de vibración de alta resolución recopilados en experimentos con seis rodamientos sanos y 26 conjuntos de rodamientos dañados. De estos, 12 fueron dañados artificialmente y 14 mediante pruebas de vida útil acelerada para simular fallas reales.



(b)


CONJUNTOS DE DATOS

C. CONJUNTO DE DATOS FEMTO

El conjunto FEMTO es proporcionado por el Instituto FEMTO-ST, Besanzón, Francia.

Incluye datos reales de pruebas de vida útil acelerada en rodamientos, generadas usando una plataforma experimental llamada PRONOSTIA.

La plataforma incluso puede generar datos sintéticos.



C O N J U N T O S D E D A T O S

D. CONJUNTO DE DATOS MFPT

Otro conjunto de datos para detección y diagnóstico de fallas en rodamientos es el MFPT dataset, proporcionado por la Society for Machinery Failure Prevention Technology.

El objetivo de esta base de datos de fallas para mantenimiento basado en condiciones (CBM) es ofrecer diferentes conjuntos de datos con condiciones tanto buenas como defectuosas para rodamientos y engranajes.

CONJUNTOS DE DATOS

E. CONJUNTO DE DATOS IMS

Este conjunto es proporcionado por el Centro de Sistemas de Mantenimiento Inteligente (IMS) de la Universidad de Cincinnati y puede descargarse desde el repositorio de datos de pronóstico alojado por la NASA. Este repositorio recopila conjuntos de datos donados por universidades, agencias o empresas, enfocados exclusivamente en datos para desarrollo de algoritmos de pronóstico.





Figure 1: IMS test rig layout [1].

MODELOS MÁS POPULARES

A. AUTOENCODERS Y AUTOENCODERS MODIFICADOS

Los autoencoders (AEs) son redes neuronales artificiales utilizadas para aprender representaciones eficientes de datos, comúnmente para tareas de reducción de dimensionalidad o extracción de características.

En un autoencoder, los datos de entrada son comprimidos en un espacio de representación de menor dimensión mediante un codificador (encoder) y luego reconstruidos en su forma original por un decodificador (decoder).



El objetivo del entrenamiento es minimizar la diferencia entre la entrada y la salida reconstruida, es decir, minimizar el error de reconstrucción.

MODELOS MÁS POPULARES

A. AUTOENCODERS Y AUTOENCODERS MODIFICADOS


Los autoencoders son útiles en tareas de diagnóstico de fallas porque pueden aprender representaciones significativas de señales de vibración sin necesidad de etiquetado.

los autoencoders también se han utilizado como parte de arquitecturas híbridas, combinándolos con otros modelos de clasificación como máquinas de soporte vectorial (SVM), redes convolucionales o redes recurrentes, lo cual permite mejorar la precisión del diagnóstico en escenarios reales con ruido y datos desbalanceados.

MODELOS MÁS POPULARES

B. REDES NEURONALES CONVOLUCIONALES (CNNs)

En el caso de las señales unidimensionales, como las vibraciones de rodamientos, se han adaptado versiones 1D de CNNs. En estas, tanto la propagación hacia adelante (forward propagation, FP) como la retropropagación (backpropagation, BP) se realizan mediante operaciones sobre arreglos (arrays), en lugar de matrices, lo que las hace más eficientes para datos secuenciales.




En un estudio, se propuso una red neuronal convolucional profunda adaptativa jerárquica (ADCNN) aplicada al conjunto de datos de CWRU. El modelo incluye dos componentes jerárquicos: una capa para determinar si existe una falla y otra para evaluar el tamaño de la falla.

Otro trabajo utilizó una CNN con fusión de múltiples sensores para el diagnóstico de maquinaria rotativa. Se combinaron datos espaciales y temporales en bruto de los sensores del lado del ventilador y del motor.

MODELOS MÁS POPULARES

B. REDES NEURONALES CONVOLUCIONALES (CNNs)

Otro trabajo utilizó una CNN con fusión de múltiples sensores para el diagnóstico de maquinaria rotativa. Se combinaron datos espaciales y temporales en bruto de los sensores del lado del ventilador y del motor.



- Estas señales de vibración 1D se transformaron en matrices 2D, que luego se utilizaron como entrada de la CNN.
- No se necesitó extracción manual de características, ya que el modelo aprendió directamente de las señales en bruto.
- Se usó el 70% de los datos para entrenamiento, 15% para validación y 15% para prueba.
- La precisión promedio fue de 99.41% usando dos sensores, y de 98.35% con un solo sensor.
- Se utilizó descenso de gradiente estocástico por mini-lotes y dropout para prevenir el sobreajuste.

MODELOS MÁS POPULARES

B. REDES NEURONALES CONVOLUCIONALES (CNNs)

En otro estudio se propuso un enfoque de diagnóstico inteligente de fallas con CNNs utilizando técnicas de aumento de datos (data augmentation).

Se aplicaron cinco métodos:

- Ruido gaussiano,
- Ruido enmascarado,
- Traslación de señal,
- Desplazamiento de amplitud
- Estiramiento temporal.

Se utilizaron directamente señales de vibración en bruto sin preprocesamiento, procesadas por una CNN 1D con bloques residuales (residual blocks) para aprender representaciones abstractas. Se aplicó normalización por lotes (batch normalization), padding para mantener la dimensión de los mapas de características, y dropout.

La función de activación fue ReLU, y SoftMax como clasificador con 400 muestras de entrenamiento, la mejor precisión fue de 99.91%

MODELOS MÁS POPULARES

DESAFÍOS DEL USO DE MODELOS DE APRENDIZAJE PROFUNDO (DL)

Aunque existe una extensa literatura publicada sobre implementaciones de DL en sistemas de detección de fallas (FDD), estas requieren conocimiento previo sobre su arquitectura.

Por eso muchas aplicaciones industriales no suelen preferir esta herramienta de tipo "caja negra".

Las condiciones de operación de los sistemas mecánicos son muy complejas y cambian constantemente según los requerimientos de producción. Por eso es poco realista recopilar y etiquetar suficientes muestras de entrenamiento para que los algoritmos DL funcionen adecuadamente en la detección y diagnóstico de fallas en rodamiento

DL tiene un mal desempeño cuando el conjunto de datos está desbalanceado. Tiende a clasificar incorrectamente la clase con mayor cantidad de muestras. Además, lograr un conjunto de datos balanceado de rodamientos es en sí mismo un desafío importante

MODELOS MÁS POPULARES

DESAFÍOS DEL USO DE MODELOS DE APRENDIZAJE PROFUNDO (DL)

Entrenar modelos DL es extremadamente costoso desde el punto de vista computacional y económico

las redes convolucionales (CNN) dependen en gran medida de datos etiquetados y pueden requerir muchas capas para aprender toda la jerarquía.

Las redes neuronales recurrentes (RNN), enfrentan el problema de desvanecimiento/explosión del gradiente

el aprendizaje por refuerzo (RL) necesita supervisión constante del sujeto y también requiere conocer hacia dónde conducen las acciones para poder estimar y tomar decisiones.